

Вопросы к контрольной работе

Машинное обучение

На все вопросы ожидаются развернутые и подробные ответы с формулами. Во всех вопросах необходимо уметь расшифровывать все обозначения.

В работе формулировки вопросов могут отличаться.

1. Что такое объект, целевая переменная, признак, модель, функция потерь, функционал ошибки и обучение?
2. Какие бывают типы признаков?
3. Что такое переобучение и недообучение? Как отличить переобучение от недообучения?
4. Что такое кросс-валидация и для чего она используется? Чем применение кросс-валидации лучше, чем разбиение выборки на обучение и контроль?
5. Чем гиперпараметры отличаются от параметров?
6. Запишите формулы для линейной модели регрессии и для среднеквадратичной ошибки. Запишите среднеквадратичную ошибку в матричном виде.
7. Что такое градиент? Какое его свойство используется при минимизации функций?
8. Запишите формулу для одного шага градиентного спуска. Чем отличается один шаг стохастического градиентного спуска? Почему не всегда можно использовать полный градиентный спуск?
9. Для чего нужно нормировать данные при обучении линейных моделей? Какие способы нормировки вы знаете?
10. Что такое регуляризация? Для чего ее используют в линейных моделях? Запишите L1- и L2-регуляризаторы. Почему L1-регуляризация отбирает признаки?
11. Запишите формулу для линейной модели классификации. Что такое отступ? Как обучаются линейные классификаторы и для чего нужны верхние оценки пороговой функции потерь?
12. Как в логистической регрессии выполняются предсказания для новых объектов? Запишите функционал логистической регрессии. Как он связан с методом максимума правдоподобия?
13. Что такое точность, полнота и F-мера?
14. Что такое AUC-ROC? Опишите алгоритм построения ROC-кривой.
15. В чём заключаются one-vs-all и all-vs-all подходы к многоклассовой классификации?
16. В чём заключается подход с независимой классификацией в задаче классификации с пересекающимися классами?
17. Что такое микро- и макро-усреднение при оценивании качества многоклассовой классификации?
18. Что такое решающее дерево? Запишите формулу предсказания решающего дерева (через разбиение признаков на области).
19. Опишите жадный алгоритм обучения решающего дерева. Запишите функционал, который оптимизируется при построении вершины решающего дерева.

20. Какими основными свойствами должен обладать критерий информативности? Как он используется для выбора предиката во внутренней вершине решающего дерева?
21. Запишите критерий Джини и энтропийный критерий информативности.
22. Как во взвешенном методе k ближайших соседей выполняются предсказания в задачах классификации и регрессии? Приведите примеры выбора весов объектов.
23. Каковы проблемы использования метода k ближайших соседей на практике?
24. Запишите формулы для следующих функций расстояния: расстояние Минковского, евклидово расстояние, манхэттэнское расстояние, расстояние Чебышева, косинусное расстояние, расстояние Джаккарда. В каком признаковом пространстве используется каждая функция расстояния?
25. Что такое композиция алгоритмов машинного обучения? Покажите, что в предположении некоррелированных ошибок базовых алгоритмов, ошибка композиции будет в N раз меньше, чем средняя ошибка базовых алгоритмов, где N - число базовых алгоритмов.
26. Что такое бэггинг? Что такое случайный лес? Что такое out-of-bag ошибка, для чего она используется?
27. Опишите алгоритм построения композиции методом градиентного бустинга. Что такое сдвиги?
28. Что такое сокращение шага в градиентном спуске и для чего оно используется?
29. Что такое стекинг и как он работает? Для чего он используется?
30. Запишите формулы для шума, смещения и разброса метода обучения.
31. Приведите пример семейства алгоритмов с низким смещением и большим разбросом; семейства алгоритмов с большим смещением и низким разбросом. Поясните примеры.
32. Что можно сказать про смещение и разброс композиции, построенной бэггингом, в сравнении со смещением и разбросом одного базового алгоритма? Для построенной бустингом композиции?
33. Запишите постановку задачи построения рекомендательной системы.
34. Опишите, как работают: content-based подход к построению рекомендательных систем, memory-based подход, подход на основе скрытых представлений. В чем состоит обучение и предсказание в этих подходах?
35. Что такое задача кластеризации? Как измеряется качество в задаче кластеризации? Запишите формулы для внутрикластерного и межкластерного расстояний.
36. Опишите, как работает метод K-Means. Какой критерий он оптимизирует?
37. Опишите, как работает метод DBSCAN.
38. Как работает подход к кластеризации, основанный на графах? Как работает иерархическая кластеризация?
39. Запишите постановку задачи понижения размерности. Запишите модель и оптимизационную задачу метода главных компонент (PCA) как задачи понижения размерности. Запишите решение этой оптимизационной задачи и его основные свойства.
40. Что такое задача визуализации? Какой критерий оптимизируют в методе Multi-Dimensional Scaling?

41. Что такое вычислительный граф? Приведите пример вычислительного графа.
Для чего нужны проход вперед и назад?
42. Запишите формулу автоматического дифференцирования.
43. Что получают на вход и что выдают на выход функции forward и backward при реализации вершины вычислительного графа, соответствующей функции $c = f(a, b)$?
44. Запишите формулы прохода вперед для полносвязного слоя, сверточного слоя, рекуррентного, слоя нелинейности, слоя softmax.
45. Приведите пример полносвязной архитектуры, решающей задачу многоклассовой классификации. Как будет выполняться обучение этой модели?
46. Запишите формулы следующих функций нелинейности: sigmoid, ReLU. В чем их преимущества и недостатки?
47. Что такое дропаут и батч-нормализация? Для чего они используются? Как выполняется проход вперед в этих слоях в режиме обучения и режиме тестирования?
48. Что такое аугментация данных? Для чего она используется?
49. Как устроены архитектуры LeNet, AlexNet, VGG, ResNet? Каковы их основные особенности?
50. Что означают данные термины: Seq2seq, BPE, RNN, Transformer, beam search, BLEU, BERT?
51. Опишите основную идею механизма self-attention: как выполняется проход вперед в этом слое?